

유니 코드

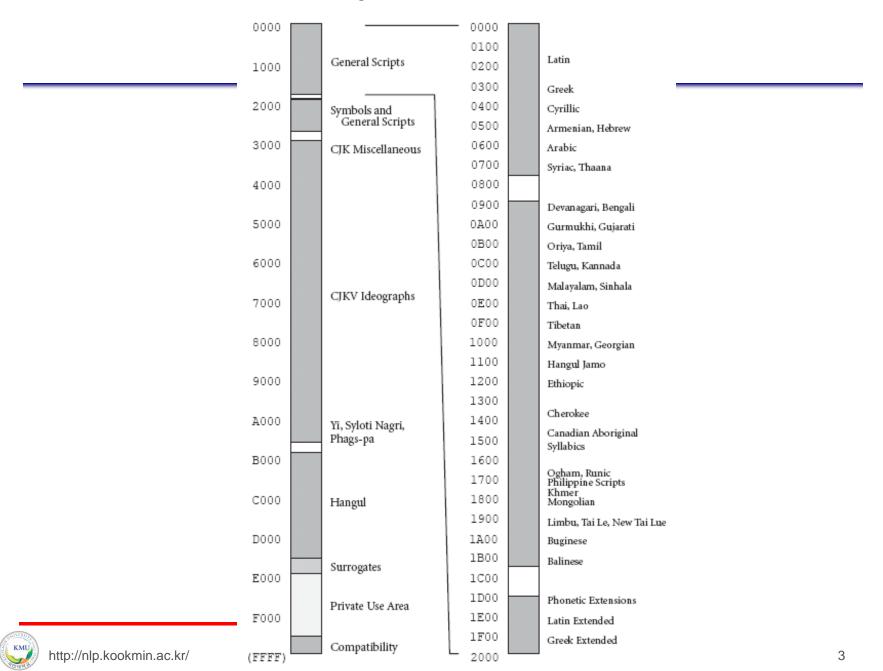
국민대학교 소프트웨어학부 강 승 식

What is unicode?

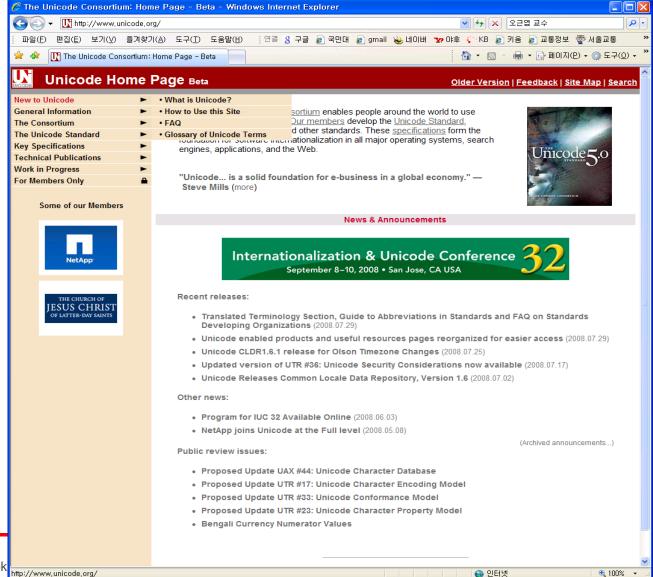
- BMP(Basic Multilingual Plane), SMP
- UCS-2, UCS-4
- UTF-8, UTF-16, UTF-32
- BOM(Byte Order Mark)
- Big Endian, Little Endian
- 유니코드 문자셋 정의 영역: 언어별로
 - 각 언어별 문자 인식 방법
 - 한글/한자/아랍어/러시아어 등 어떤 영역의 문자인지 확인 방법
 - 다국어 문자가 혼합되어 있을 때 언어별로 tokenization

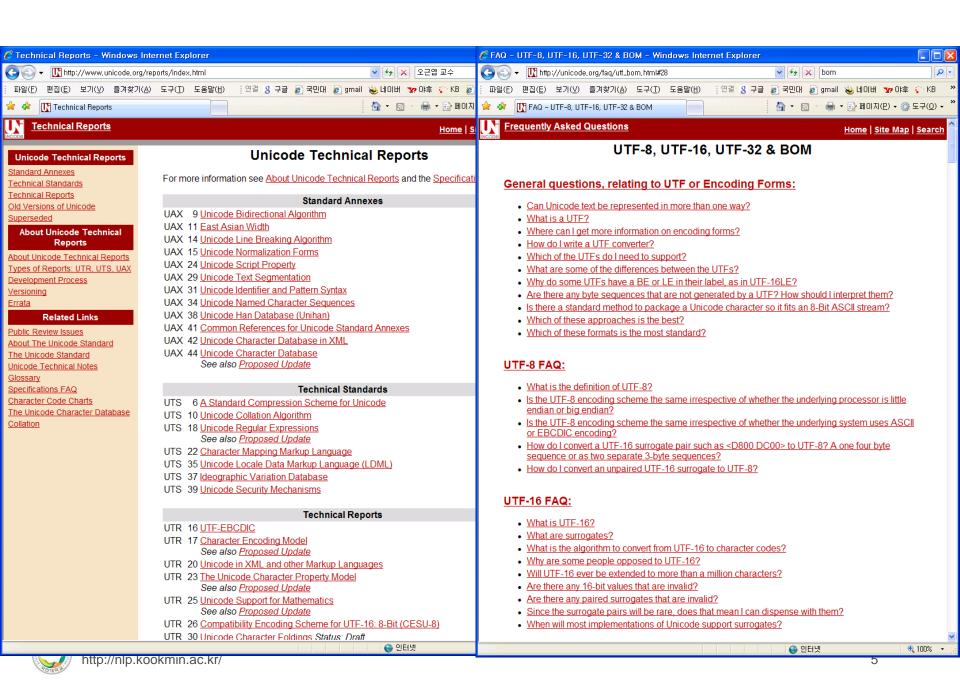


Figure 2-14. Allocation on the BMP



http://www.unicode.org/







The Unicode Character Code Charts By Script

updated for Unicode 5.1

SYMBOLS AND PUNCTUATION | NAME INDEX | HELP AND LINKS

European Alphabets	African Scripts	Indic Scripts	East Asian Scripts	Central Asian Scripts
(see also Comb. Marks)	Ethiopic	Bengali	Han Ideographs	Kharoshthi
Armenian	Ethiopic	Devanagari	Unified CJK Ideographs (5MB)	Mongolian
Armenian	Ethiopic Supplement	Gujarati	CJK Ideographs Ext. A (2MB)	Phags-Pa
Armenian Ligatures	Ethiopic Extended	Gurmukhi	CJK Ideographs Ext. B (13MB)	Tibetan
Coptic	Other African scripts	Kannada		Ancient Scripts
Coptic	N'Ko	Lepcha	Compatibility Ideographs (.5MB)	Ancient Greek
Coptic in Greek block	Osmanya	Limbu	Supplement (.5MB)	Ancient Greek Numbers
Cyrillic	Tifinagh	Malayalam	Kanbun	Ancient Greek Musical
Cyrillic	Vai	Ol Chiki	(see also Unihan Database)	Cuneiform
Cyrillic Supplement	Middle Eastern Scripts	Oriya	Radicals and Strokes	Cuneiform
Cyrillic Extended A	Arabic	Saurashtra	CJK Radicals	Cuneiform Numbers
Cyrillic Extended B	Arabic	Sinhala	KangXi Radicals	Old Persian
Georgian	Arabic Supplement	Syloti Nagri	CJK Strokes	Ugaritic
Georgian	Arabic Present. Forms A	Tamil	Ideographic Description	Linear B
Georgian Supplement	Arabic Present. Forms B	Telugu	Chinese-specific	Linear B Syllabary
Greek	Hebrew	South East Asian	Bopomofo	Linear B Ideograms
Greek	Hebrew	Balinese	Bopomofo Extended	Other Ancient Scripts
Greek Extended	Hebrew Present. Forms	Buginese	Japanese-specific	Aegean Numbers
(see also Ancient Greek)	Syriac	Cham	Hiragana	Ancient Symbols
Latin	Syriac	Kayah Li	Katakana	Carian
Basic Latin	Thaana	Khmer	Katakana Phonetic Ext.	Counting Rod Numerals
Latin-1	Thaana	Khmer Symbols	Halfwidth Katakana	Cypriot Syllabary
Latin Extended A	American scripts	Lao	Korean-specific	Glagolitic
Latin Extended B	Canadian Syllabics	Myanmar	Hangul Syllables (4MB)	Gothic
Latin Extended C	Cherokee	New Tai Lue	Hangul Jamo	Lycian
Latin Extended D	Deseret	Rejang	Hangul Compatibility Jamo	Lydian
Latin Extended Additional	Philippine Scripts	Sundanese	Halfwidth Jamo	Ogham
Latin Ligatures	Buhid	Tai Le	Yi	Old Italic
Fullwidth Latin Letters	Hanunoo	Thai	Yi (.6MB)	Phaistos Disc
Small Forms	Tagalog	Other Scripts	Yi Radicals	Phoenician
(see also Phonetic Symbols)	Tagbanwa	Shavian		Runic

To get a list of code charts for a character, enter its code in the search box at the top. To access a chart for a given block, click on its entry in the table. The charts are PDF files, and some of them may be very large. For frequent access to the same chart, right-click and save the file to your disk. For an alphabetical index of character and block names, use the Unicode Character Names Index. For terms of use, conventions used in this table, access to additional charts and ways to access the code charts, see Character Code Chart Help and Links.

😝 인터넷



유니코드 2.0

- 한글 11,172자를 순서대로 코드 부여
 - 코드 범위: '가'(0xAC00) ~ '힣'(0xD7A3)
- 자모 코드(0x31xx 영역)
 - 자음: 0x3131 ~ 0x314E
 - 모음 : 0x314F ~ 0x3163
 - 채움 코드: 0x3164
 - 옛글 자모: 0x3165 ~ 0x318E
- 초성-중성-종성 코드(0x11xx 영역)
- CJKV 한자 코드
 - 한-중-일 공통 한자는 1개의 코드 부여
 - 음가 2 이상인 한자에 하나의 코드만 부여



유니코드에서 초성/중성/종성 인식

• 초성

```
( ( 코드값 - 0xACOO ) / 28 ) / 21 ) % 19
```

중성

```
( ( 코드값 - 0xACOO ) / 28 ) % 21
```

• 종성

```
( 코드값 - 0xAC00 ) % 28
```

유니코드 <-> KS완성형 변환

- 유니코드 <-> KS완성형 변환
 - 한글 11,172자
 - 자모
 - 문장부호: 가운데점 등
 - _ 한자
- 코드변환 테이블 작성
 - Windows의 notepad(메모장) 이용
- Java, Perl에서 유니코드-완성형 변환 방법
- "iconv" 라이브러리 사용

Topics

- 1. Unicode란 무엇인가?
- Unicode의 특징, EUC-KR과 다른 점 등
- Unicode의 한글영역: 음절, 자음과 모음, 특수문자(가운데점 등)
- 2. Unicode의 국가별 문자셋 영역(한글 제외)
- 아시아 언어 영역 -- 일본어 영역, 중국어(한자) 영역 등
- 유럽어 영역 -- 독일어의 움라우트, 러시아어 등
- 아랍어 영역
- 기타 언어 영역

3. Tokenization program 작성

한/중/일/아랍어/러시아어/문장부호 등이 혼합된 입력 문자열에 대해 각 언어 영역별로 문자열을 분리하는 프로그램

4. Unicode Encoding Forms UTF-8, UTF-16, UTF-32

5. Unicode 관련 용어 설명 http://www.unicode.org/의 "Glossary of Unicode Terms" 참조

- Big Endian, Little Endian
- BMP Code Point, Supplementary Code Point, Surrogate Code Point, High-Surrogate Code Point
- BOM(Byte Order Mark)
- CJK
- Code Page, Code Point, Codespace
- DBCS, SBCS
- Consonant, Vowel, Diphthong, Jamo, Leading Consonant
- Syllable block, Hangul Syllable Block

